

See discussions, stats, and author profiles for this publication at: <https://www.researchgate.net/publication/371368784>

Aplikasi ARCH/GARCH dalam Prediksi Harga Saham PT Kimia Farma (Persero) Tbk

Conference Paper · January 2021

DOI: 10.1234/pns.v10i.72

CITATIONS

0

READS

97

5 authors, including:



Mohammad Hamid Asnawi

Universitas Padjadjaran

9 PUBLICATIONS 10 CITATIONS

SEE PROFILE



Syifa Auliyah Hasanah

Universitas Padjadjaran

3 PUBLICATIONS 5 CITATIONS

SEE PROFILE



Amsal Esa Hasana

Universitas Padjadjaran

2 PUBLICATIONS 1 CITATION

SEE PROFILE



Aplikasi ARCH/GARCH dalam Prediksi Harga Saham PT Kimia Farma (Persero) Tbk

Mohammad Hamid Asnawi¹, Syifa Auliyah Hasanah², Vyola Mentari Gizela³, Amsal Esa Hasana⁴, Toni Toharudin⁵

Universitas Padjadjaran^{1, 2, 3, 4, 5}

mohammad19011@mail.unpad.ac.id, syifa19010@mail.unpad.ac.id, vyola19001@mail.unpad.ac.id,
amsal19001@mail.unpad.ac.id, toni.toharudin@unpad.ac.id

Abstract

Abstrak. ARIMA merupakan salah satu metode dalam melakukan peramalan pada data yang berbentuk time series. Namun, adanya pelanggaran asumsi pada pemodelan ARIMA membuat pemodelan atau peramalan tersebut tidak lagi valid, misalnya saja pada pelanggaran terkait heteroskedastisitas. Maka, untuk memodelkan volatilitas dari data tersebut diperlukan adanya pemodelan menggunakan ARCH-GARCH agar pelanggaran asumsi heteroskedastisitas pada ARIMA tidak menjadi penghalang untuk tetap melanjutkan analisis. Data terkait saham PT. Kimia Farma Tbk. yang diambil pada periode Juli 2016 hingga Juni 2021, akan dijadikan sebagai media dalam pengaplikasian metode ARCH-GARCH dalam kasus saham. Hasil penelitian menunjukkan bahwa setelah didapatkan model ARIMA yang cocok, maka didapatkan residual yang selanjutnya akan diuji heteroskedastisitasnya dengan menggunakan uji Lagrange Multiplier (LM). Diperoleh hasil bahwa model ARCH (0,1) merupakan model yang tepat untuk meramalkan data historis saham PT. Kimia Farma Tbk. Menggunakan model ARCH (0,1) akan dilakukan peramalan hingga akhir tahun, yakni bulan Juli – Desember 2021. Sehingga bisa memberikan gambaran serta informasi terkait kondisi saham PT. Kimia Farma Tbk. yang membantu para calon investor.

Kata kunci: Time series, volatilitas, heteroskedastisitas, ARIMA, ARCH-GARCH

I. PENDAHULUAN

Adanya pandemi Covid-19 memberikan dampak bagi beberapa sektor kehidupan, terutama sektor ekonomi. Pandemi ini menimbulkan melemahnya sektor-sektor lain yang menimbulkan adanya efek domino terhadap sektor ekonomi. Resesi ekonomi merupakan permasalahan yang tidak bisa dihindari lagi bagi Indonesia. Berbagai cara dilakukan pemerintah agar bisa memulihkan perekonomian, salah satunya adalah vaksinasi bagi masyarakat. Dengan adanya kegiatan vaksinasi tersebut membuat saham berbagai perusahaan farmasi melesat dari sebelumnya, salah satunya adalah saham milik PT. Kimia Farma Tbk.

Kimia Farma merupakan salah satu perusahaan yang bergerak dalam industri farmasi. Didirikan pada tahun 1817 membuat Kimia Farma menjadi perusahaan industri farmasi tertua di Indonesia. Berbagai kebijakan yang terjadi, membuat perusahaan tersebut telah berganti nama beberapa kali, yakni NV Chemicalien Handle Rathkamp & Co. menjadi PNF (Perusahaan Negara Farmasi) Bhinneka Kimia Farma pada tahun 1958, dan barulah pada tanggal 16 Agustus 1971 berganti nama menjadi PT Kimia Farma (Persero) hingga saat ini. Kode emiten bagi saham Kimia Farma yaitu KAEF, dengan komposisi 90,025% merupakan saham milik pemerintah dan 9,975% saham milik publik. Pada Tanggal 28 Februari 2020 pemerintah Indonesia melakukan proses inbreg untuk pengalihan dalam kepemilikan saham seri B sebesar 4.999.999.999 kepada PT. Biofarma.

Deret waktu merupakan sebuah analisis statistika yang digunakan untuk mendapatkan model prediksi terhadap data yang akan datang dengan menggunakan data-data yang didapatkan melalui hasil pengamatan dari waktu ke waktu. Adanya varians yang tidak tetap pada data deret waktu merupakan sebuah pelanggaran asumsi pada pemodelan ARIMA, sehingga diperlukan adanya pemodelan ARCH-GARCH untuk mengatasi pelanggaran tersebut.

Penelitian ini membahas tentang peramalan data historis saham PT. Kimia Farma Tbk. menggunakan metode ARCH/GARCH. Data yang digunakan merupakan data historis saham PT. Kimia Farma Tbk. bulanan mulai Juli 2016 sampai Juni 2021.





II. METODE PENELITIAN

2.1 Landasan Teori

2.1.1 Saham

Salah satu dokumen berharga yang memuat mengenai kepemilikan kekayaan salah satu perusahaan dikenal dengan saham. Kekayaan sebuah perusahaan bisa dilihat dari nilai saham atau harga saham dari perusahaan yang menerbitkannya. Kekuatannya berada pada permintaan dan penawaran pada pasar sekunder (pasar bursa). Naik turunnya suatu saham bergantung pada proses jual beli oleh para investor. Banyaknya investor yang akan menjual sahamnya mengindikasikan bahwa saham tersebut turun, begitu sebaliknya [1]. Adanya perubahan secara fluktuasi terhadap harga-harga saham yang tidak menentu disebut volatilitas. Terjadinya volatilitas secara acak membuat para investor membutuhkan gambaran mengenai volatilitas dalam peramalan harga saham kedepannya [2].

2.1.2 Peramalan dan Deret Waktu

Deret waktu atau *time series* merupakan suatu kumpulan data yang memiliki urutan dalam waktu pengambilan. Pada data deret waktu memiliki empat pola, yaitu trend, musiman, horizontal, dan siklus. Pola trend merupakan pola yang cenderung memiliki arah dalam jangka panjang berupa naik turun data. Pola musiman yaitu pola yang memiliki fluktuasi data secara periodik dalam kurun waktu tertentu. Pola horizontal yaitu merupakan pola dari kejadian tak terduga yang memiliki sifat acak, tetapi apabila muncul menyebabkan fluktuasi data *time series*. Sedangkan pola siklus merupakan fluktuasi dari data untuk waktu yang lebih dari satu tahun. Salah satu teknik statistik yang bisa memprediksi terkait kejadian di masa depan berdasarkan urutan waktu dinamakan Analisis deret waktu [3].

2.1.3 Uji Stasioner Data

Menurut kamus besar bahasa Indonesia, stasioner berarti tetap, tidak berubah, ajek baik itu mengenai jumlah, nilai, ukuran, posisi, dan sebagainya. Dalam *time series forecasting*, stasioneritas memiliki arti tidak adanya naik turun dalam data. Menurut [4] apabila terjadi keseimbangan antara nilai rata-rata dan varians yang konstan pada waktu tertentu, maka data tersebut dapat dikatakan stasioner. Data deret waktu yang diperoleh dapat ditunjukkan kestasionerannya terhadap varians dengan metode analisis deret waktu [4]. Berbagai cara dapat dilakukan untuk menguji kestasioneran suatu data, diantaranya :

1. Plot Deret Waktu (*Time Series*)

Jika rata-rata dan varians yang didapat dari waktu ke waktu bernilai konstan, maka dapat dikatakan data tersebut cenderung stasioner, jika varians cenderung naik turun, maka perlu dilakukan *differencing* terhadap data agar data stasioner.

2. Plot ACF dan PACF

Jika nilai ACF masing-masing inersia mendekati nol atau sama maka data bersifat stasioner, jika nilai ACF relatif tinggi dan mendekati satu maka data bersifat tidak stasioner.

3. Uji Unit Root

Uji akar unit merupakan pengujian yang berfungsi untuk melihat apakah suatu koefisien yang ditaksir dalam model autoregresif apakah memiliki suatu nilai atau tidak. Secara umum, terdapat tiga uji yang biasa dilakukan dalam uji *unit root*, yaitu uji *Augmented Dickey-Fuller* (ADF), *Philps Perron* (PP), *Kwiatkowski Phillips Schmidt Shin* (KPSS) [5].

2.1.4 Proses Differencing Data

Data deret waktu yang tidak stasioner harus diubah menjadi data stasioner dengan proses *differencing*, yaitu menghitung perubahan atau perbedaan nilai pengamatan. Dilakukan pengecekan terhadap nilai selisih yang diperoleh untuk mengetahui apakah data sudah stasioner atau belum. Jika belum stasioner maka dilakukan *differencing* lagi dengan persamaan:

$$\Delta Y_t = Y_t - Y_{t-1} \quad (1)$$

dengan

Y_t : Variabel pengamatan pada waktu ke t

Y_{t-1} : Variabel pengamatan pada waktu ke $t-1$

t : waktu

2.1.5 Model Deret Waktu

Berdasarkan modelnya, data-data tersebut mempunyai metode dengan karakteristik yang berbeda yang dapat dijadikan patokan untuk memilih model mana yang sesuai dan tepat untuk melakukan proses peramalan. Beberapa model deret waktu tersebut adalah [6]:



**1. Model AR(p)**

Deret waktu \bar{Y}_t adalah proses AR (*Auto Regressive*) orde p atau AR(p), yang dapat dinyatakan dengan:

$$Y_t = \Phi_1 Y_{t-1} + \Phi_2 Y_{t-2} + \dots + \Phi_p Y_{t-p} + e_t \quad (2)$$

Artinya, \bar{Y}_t merupakan kombinasi linier p buah nilai-nilai sebelumnya ditambah dengan kekeliruan pada waktu t. Variabel kekeliruan e_t diasumsikan saling bebas terhadap $Y_{t-1}, Y_{t-2}, \dots, Y_{t-p}$ dan berdistribusi normal dengan rata-rata 0 dan varians σ^2 .

2. Model MA(q)

Model MA (*Moving Average*) orde q adalah deret \bar{Y}_t yang dibentuk dengan menghitung *error* pada waktu t dan *error* sebelumnya yang diberi bobot, sehingga dapat dinyatakan sebagai:

$$Y_t = e_t - \theta_1 e_{t-1} - \theta_2 e_{t-2} - \dots - \theta_q e_{t-q} \quad (3)$$

3. Model ARMA(p,q)

Model ARMA (*Auto Regressive Moving Average*) orde p dan q proses *time series* yang dibangun dari penggabungan AR(p) dan MA(q) dengan persamaan sebagai berikut:

$$Y_t = \Phi_1 Y_{t-1} + \dots + \Phi_p Y_{t-p} + e_t - \theta_1 e_{t-1} - \dots - \theta_q e_{t-q} \quad (4)$$

4. Model ARIMA(p,d,q)

Model ARIMA(p,d,q) merupakan kombinasi dari model ARMA(p,q) yang telah dilakukan proses *differencing* sehingga data telah stasioner. Model yang terbentuk dinyatakan sebagai:

$$\Phi_p(B)(1-B)^d Y_t = \theta_q(B)e_t \quad (5)$$

2.1.7 Metode ARCH-GARCH

Engle(1982) mengembangkan kerangka estimasi yang memperhitungkan adanya heteroskedastisitas. Oleh karena itu, estimasi parameter dapat dilakukan dengan presisi yang lebih tinggi. Kerangka estimasi yang digunakan untuk menghitung heteroskedastisitas yaitu model *Autoregressive Conditional Heteroscedastic* (ARCH). Model ini dikembangkan oleh Bollerslev (1986) dan Taylor (1986) menjadi model *Generalized Autoregressive Conditional Heteroscedastic* (GARCH) [7].

Bentuk umum dari model ARCH adalah sebagai:

$$\sigma_t^2 = \alpha_0 + \alpha_1 e_{t-1}^2 + \alpha_2 e_{t-2}^2 + \dots + \alpha_p e_{t-p}^2 \quad (6)$$

dengan

- σ_t^2 : Varian pada periode t
- α_0 : Konstanta
- $\alpha_1, \dots, \alpha_p$: Parameter ARCH
- e_{t-1}^2 : Residual pada periode t-1, i=1, 2, ..., p

Bollerslev (1986) dan Taylor (1986) mengembangkan metode ARCH dalam bentuk model GARCH dengan menggunakan bentuk persamaan umum berikut:

$$\sigma_t^2 = \alpha_0 + \alpha_1 e_{t-1}^2 + \alpha_2 e_{t-2}^2 + \dots + \alpha_p e_{t-p}^2 + \lambda_1 \sigma_{t-1}^2 + \dots + \lambda_q \sigma_{t-q}^2 \quad (7)$$

dengan

- σ_t^2 : Varian pada periode t
- α_0 : Konstanta
- $\alpha_1, \dots, \alpha_p$: Parameter ARCH
- e_{t-1}^2 : Residual pada periode t-1, i=1, 2, ..., p
- σ_{t-1}^2 : Varian periode t-1, t=1, 2, ..., q

Estimasi Parameter ARCH-GARCH

Karena model ARCH(q) dan GARCH(p,q) merupakan model non-linier, maka metode kemungkinan maksimum (*maximum likelihood*) digunakan untuk mengestimasi parameter model ARCH-GARCH.

Untuk rumus ARCH, distribusi probabilitasnya adalah:

$$P(\sigma_t^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \left[-\frac{1}{2}(\sigma_t^2 - \alpha_0 + \alpha_1 e_{t-1}^2)^2 \right] \quad (8)$$

Fungsi *Likelihood* adalah produk dari masing-masing peluang kejadian pada n buah pengamatan, sehingga:

$$LF = \frac{1}{(2\pi\sigma^2)^{\frac{n}{2}}} \exp \left[-\sum_{t=1}^n \left(\frac{\sigma_t^2 - \alpha_0 + \alpha_1 e_{t-1}^2}{2\sigma^2} \right)^2 \right] \quad (9)$$

Dengan memaksimumkan nilai fungsi *likelihood* (LF) pada persamaan diatas, metode kemungkinan maksimum membuat sedemikian sehingga probabilitas σ_t^2 bernilai setinggi mungkin. Hal ini dapat dilakukan dengan menurunkan fungsi tersebut terhadap setiap parameter yang ada, kemudian disamadengkan nol. Untuk memudahkan, persamaan LF diubah menjadi bentuk logaritma natural (*ln*). Memaksimumkan nilai fungsi *ln* LF sama dengan memaksimumkan fungsi LF.





$$\ln LF = -n \ln \sigma^2 - \frac{n}{2} \ln(2\pi) - \frac{1}{2} \sum_{t=1}^n \frac{(\sigma_t^2 - \alpha_0 + \alpha_1 e_{t-1}^2)^2}{\sigma^2} \quad (10)$$

Selanjutnya, untuk persamaan (5) terhadap α_0, α_1 sehingga didapat:

$$\frac{\partial \ln LF}{\partial \alpha_0} = -\frac{1}{\sigma^2} \sum_{t=1}^n (\sigma_t^2 - \alpha_0 + \alpha_1 e_{t-1}^2)(e_{t-1}^2) \quad (11)$$

Buat persamaan (5) dan (6) sama dengan nol, sehingga didapat rumusan untuk mencari taksiran dari kemungkinan maksimum.

$$\frac{1}{\sigma^2} \sum_{t=1}^n (\sigma_t^2 - \alpha_0 + \alpha_1 e_{t-1}^2)(e_{t-1}^2) = 0 \quad (12)$$

Sehingga didapat:

$$\sum_{t=1}^n \sigma_t^2 e_{t-1}^2 = (\alpha_0 \sum_{t=1}^n e_{t-1}^2 + \alpha_1 \sum_{t=1}^n e_{t-1}^4) \quad (13)$$

Sehingga didapat nilai taksiran parameter

$$\alpha_0 = \overline{\sigma_t^2} - \overline{\alpha_1 e_{t-1}^2} \quad (14)$$

$$\alpha_1 = \frac{\sum_{t=1}^n \sigma_t^2 e_{t-1}^2 - (\sum_{t=1}^n \sigma_t^2)(\sum_{t=1}^n e_{t-1}^2/n)}{(\sum_{t=1}^n e_{t-1}^4) - (\sum_{t=1}^n e_{t-1}^2)^2/n} \quad (15)$$

2.1.8 Nilai Ketepatan Prediksi Mean Absolute Percentage Error (MAPE)

Menurut [8], $\alpha_0 \sum_{t=1}^n e_{t-1}$ Mean Absolute Percentage Error (MAPE) dihitung menggunakan kesalahan *absolute* untuk setiap periode dibagi dengan nilai aktual yang diamati selama periode tersebut. Nilai MAPE dapat dihitung dengan persamaan berikut:

$$MAPE = \left(\frac{100\%}{n} \right) \sum_{t=1}^n \frac{|X_t - F_t|}{X_t} \quad (15)$$

dimana

X_t : Data aktual pada periode t

F_t : Nilai peramalan pada periode t

2.2 Metodologi Penelitian

Berikut langkah-langkah yang dilakukan dalam analisis:

1. Uji Kestasioneran Data

Uji kestasioneran data dilakukan untuk melihat apakah data sudah stasioner dalam rata-rata maupun varians, jika belum stasioner dilakukan *differencing* sampai data stasioner.

2. Identifikasi Model

Kestasioneran data dilihat melalui plot deret waktu, plot ACF, plot PACF, dan uji unit root. Dari plot ACF dan plot PACF dapat diidentifikasi kombinasi model yang sekiranya cocok dengan peramalan.

3. Estimasi Parameter Model

Lakukan estimasi parameter setelah terpilih beberapa model untuk mengetahui nilai koefisien terbaik dari model.

4. Pemilihan Model Terbaik

Lakukan uji residual untuk memverifikasi model, apakah model yang digunakan baik atau tidak.

5. Peramalan

Lakukan peramalan pada data, setelah nilai peramalan didapat selanjutnya dilakukan pencarian residual model dengan cara menghitung selisih antara data aktual dengan data hasil peramalan.

6. Uji ARCH-LM

Untuk melanjutkan uji ARCH-GARCH dilakukan uji ARCH-LM untuk melihat keberadaan heteroskedastisitas, jika tidak terdapat unsur heteroskedastisitas maka peramalan cukup menggunakan metode *Box-jenkins*.

7. Identifikasi Model ARCH-GARCH

Estimasi dilakukan untuk menentukan nilai koefisien dan model ARCH-GARCH.

8. Estimasi Parameter Model ARCH-GARCH

Estimasi dilakukan untuk mencari nilai koefisien dalam model.

9. Verifikasi Model

Dilakukan uji independensi residual dan uji kenormalan residual untuk melihat apakah model ARCH-GARCH baik atau tidak digunakan.

10. Peramalan

Setelah didapat model terbaik, maka dilakukan peramalan untuk memprediksi perubahan harga saham.





2.3 Data

Pada penelitian yang menggunakan metode ARCH-GARCH ini, digunakan data saham KAEF dari bulan Juli 2016 hingga Juni 2021 yang diambil dari situs resmi <https://finance.yahoo.com/quote/KAEF.JK?p=KAEF.JK&tsrc=fin-srch>. Selanjutnya akan dilakukan peramalan dengan menerapkan model ARCH-GARCH menggunakan software R.

III. HASIL DAN PEMBAHASAN

3.1 Uji Kestasioneritasan Data

Data yang tidak stasioner dalam rata-ratanya dapat distasionerkan dengan melakukan *differencing*, sedangkan data yang tidak stasioner dalam variansnya dapat distasionerkan dengan menggunakan transformasi Box-Cox.

Hipotesis

H_0 : $\delta = 0$ (Data tidak stasioner dalam rata-rata)

H_1 : $\delta < 0$ (Data stasioner dalam rata-rata)

α : 0.05

Statistik uji : *Augmented Dickey-Fuller*

Hasil Pengujian :

Tabel 1. Output Uji Augmented Dickey-Fuller


Augmented Dickey-Fuller Test		P-value
Dickey-Fuller	-4.9747	0.01

Karena hasil analisis didapatkan bahwa p-value lebih kecil dari α dengan nilai $(0.01) < (0.05)$ maka diambil keputusan untuk menolak H_0 , yang berarti data sudah stasioner dalam rata-rata, setelah dilakukan *differencing* sebanyak dua kali. Namun belum diketahui apakah data stasioner dalam varians. Apabila dalam pengujian stasioner terhadap varians didapatkan data belum stasioner, maka harus dilakukan transformasi Box-Cox.

3.2 Identifikasi Model

a. Plot Time Series

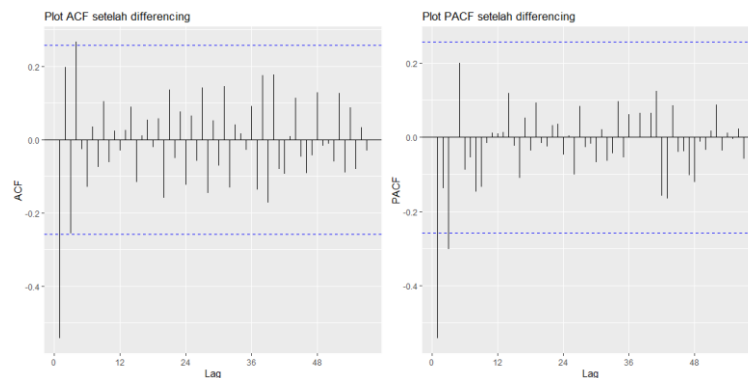
Data yang tidak stasioner dalam rata-ratanya dapat distasionerkan dengan melakukan *differencing*, sedangkan data yang tidak stasioner dalam variansnya dapat distasionerkan dengan menggunakan transformasi Box-Cox.



Gambar 1. Plot data historis saham Kimia Farma setelah *differencing*

Setelah dilakukan pengujian dengan menggunakan Box-Cox, diketahui bahwa data historis saham PT. Kimia Farma Tbk tidak stasioner dalam varians karena memiliki nilai λ sebesar 0.6654244, sehingga perlu dilakukan transformasi menggunakan perumusan $\frac{y^\lambda - 1}{\lambda}$. Dengan menggunakan software R, diperoleh bahwa nilai transformasi BoxCox Lambda sebesar 0.9719626. Karena nilai transformasi BoxCox Lambda sudah mendekati 1, maka diasumsikan bahwa data tersebut sudah stasioner terhadap varians. Selain itu, diketahui juga bahwa data tidak stasioner dalam rata-rata, sehingga perlu dilakukan proses *differencing*. Setelah dilakukan dua kali proses *differencing*, barulah data stasioner dalam rata-ratanya.



**b. Plot ACF dan PACF**Gambar 2. Plot ACF dan PACF setelah *differencing*

Berdasarkan plot diatas, dapat diketahui bahwa pada plot ACF terdapat *cut off after lag-1*, serta pada plot PACF terdapat *cut off after lag-1*.

3.3 Estimasi Parameter Model dan Pemilihan Model Terbaik

Berdasarkan plot ACF dapat diketahui bahwa data *cut off after lag-1*, maka dugaan orde MA, $q = 1$, sedangkan dari plot PACF dapat diketahui bahwa data *cut off after lag-1*, maka dugaan orde AR, $p = 1$. Sehingga model ARIMA yang bisa terbentuk adalah ARIMA (0,2,0), ARIMA (1,2,0), ARIMA (0,2,1), dan ARIMA (1,2,1). Dengan menggunakan cara *try and error* dalam menentukan model terbaiknya, maka didapatkan model terbaik yakni model ARIMA (1,2,1) dengan nilai AIC terkecil yaitu 924.6555 pada model tersebut.

Tabel 2. Estimasi Parameter Model ARIMA (3,2,1)

Parameter	Koefisien	P-value	Signifikansi
ar1	-0.754424	< 2.2e-16	Signifikan
ma1	-0.999929	< 2.2e-16	Signifikan

$$Y_t = \Phi_1(Y_{t-1} - Y_{t-2}) + \dots + \Phi_4(Y_{t-4})$$

$$Y_t = \mu - 0.754424Y_{t-1} - 0.999929e_{t-1}$$

3.4 Diagnostik Model

Model yang akan digunakan untuk peramalan terlebih dahulu harus memenuhi beberapa asumsi yakni stasioneritas data dan *White Noise residual* (berdistribusi normal, non-autokorelasi, homogenitas)

a. Uji Normalitas Residual

Hipotesis

- H_0 : Residual mengikuti distribusi normal
 H_1 : Residual tidak mengikuti distribusi normal
 α : 0.05

Tabel 3. Output Uji Normalitas Residual

Kolmogorov-Smirnov Test		P-value
D	0.17241	0.3571

Berdasarkan output diatas, diperoleh nilai p-value sebesar 0.3571. Karena nilai p-value (0.3571) > α (0.05), maka H_0 diterima. Artinya, dengan taraf signifikan 5% dapat disimpulkan bahwa residual mengikuti distribusi normal. Sehingga, asumsi normalitas terpenuhi.

b. Uji White Noise Autokorelasi

Hipotesis

- H_0 : residual tidak berautokorelasi
 H_1 : residual berautokorelasi
 α : 0.05

Tabel 4. Output Uji White Noise Autokorelasi

Box-Ljung Test		P-value
Chi-Square	0.78547	0.3755





Berdasarkan output diatas, diperoleh nilai p-value sebesar 0.3755. Karena nilai p-value (0.3755) > α (0.05), maka H_0 diterima. Artinya, dengan taraf signifikan 5% dapat disimpulkan bahwa residual tidak berautokorelasi. Sehingga, asumsi non-autokorelasi terpenuhi.

c. Uji White Noise Heteroskedastisitas

Hipotesis

H_0 : residual bersifat homogen

H_1 : residual bersifat heterogen

α : 0.05

Tabel 5. Output Uji *White Noise* Heteroskedastisitas

Box-Ljung Test		P-value
Chi-Square	4.6806	0.0305

Berdasarkan output diatas, diperoleh nilai p-value sebesar 0.0305. Karena nilai p-value (0.0305) < α (0.05), maka H_0 ditolak. Artinya, dengan taraf signifikan 5% dapat disimpulkan bahwa residual bersifat heterogen. Sehingga, asumsi homogenitas tidak terpenuhi. Karena model ARIMA (3,2,1) tidak memenuhi asumsi homogenitas, maka perlu diidentifikasi adanya efek ARCH pada model.

3.5 Uji ARCH-LM

Hipotesis

H_0 : Tidak terdapat efek ARCH pada model

H_1 : Terdapat efek ARCH pada model

α : 0.05

Tabel 6. Output Uji ARCH-LM


ARCH-LM Test		P-value
F	20.88	2.665e-05
Chi-Square	8.06	0.004525

Berdasarkan output diatas, untuk statistik uji Chi-Squared diperoleh nilai p-value sebesar 0.004525. Serta untuk statistik uji F diperoleh nilai p-value sebesar 2.665e-05. Karena kedua nilai p-value < α (0.05), maka H_0 ditolak. Artinya, dengan taraf signifikan 5% dapat disimpulkan bahwa terdapat efek ARCH pada model ARIMA (3,2,1).

3.6 Identifikasi Model ARCH/GARCH


a. Plot ACF, PACF, dan Squared Residual

Setelah diketahui bahwa terdapat efek ARCH pada data, kemudian akan dilakukan pemodelan dalam bentuk GARCH. Oleh karena itu, dilakukan identifikasi terlebih dahulu terhadap model GARCH melalui pengamatan terhadap plot ACF dan PACF *squared residuals*.



Gambar 3. Plot *Squared Residuals* Model ARIMA (1,2,1)



Gambar 4. Plot ACF dan PACF *Squared Residual* ARIMA (1,2,1)

Berdasarkan grafik plot residual kuadrat menunjukkan adanya kluster volatilitas di beberapa titik, untuk plot ACF teridentifikasi *cut off after lag-1*, begitu pula untuk untuk plot PACF teridentifikasi *cut off after lag-1*. Maka, model yang dapat terbentuk adalah ARCH (0,1), ARCH (1,0), ARCH (1,1).

b. Pemilihan Model ARCH/GARCH

Berdasarkan hasil plot ACF dan PACF dapat diketahui bahwa kemungkinan model yang dapat terbentuk adalah ARCH (0,1), ARCH (1,0), dan ARCH (1,1). Untuk melakukan pemilihan model terbaik, dilakukan pemilihan berdasarkan nilai AIC dari ketiga model ARCH. Berdasarkan hasil perhitungan menggunakan software R, diperoleh nilai AIC terkecil adalah pada model ARCH (0,1) yakni sebesar 296.4776, maka model terbaik yang dapat dipilih adalah model ARCH (0,1).

$$\sigma_t^2 = 6.264 \times 10^5 x + 2.253 \times 10^{-1} x_{t-1}^2$$

3.7 Estimasi Parameter Model ARCH/GARCH

Hipotesis

H_0 : Parameter tidak signifikan

H_1 : Parameter signifikan

α : 0.05

Tabel 7. Estimasi dan Uji Signifikansi Parameter

Parameter	Koefisien	P-value	Signifikansi
a0	6.264e+05	0.0072	Signifikan
a1	2.253e-01	0.6262	Tidak Signifikan

3.8 Verifikasi Model

a. Uji Autokorelasi

Hipotesis

H_0 : Residual tidak berautokorelasi

H_1 : Residual berautokorelasi

Tabel 8. Output Uji Autokorelasi

Box-Ljung Test		P-value
Chi-Square	0.3177	0.573

Berdasarkan tabel diatas, dapat diketahui bahwa nilai p-value yang diperoleh adalah sebesar 0.573. Karena nilai p-value (0.573) > α (0.05), maka H_0 diterima. Artinya, dengan taraf signifikan 5% dapat disimpulkan bahwa residual tidak berautokorelasi.

b. Rumusan Model

GARCH (0,1) yang diperoleh adalah :

$$h_t = 6.264 \times 10^5 x + 2.253 \times 10^{-1} \varepsilon_{t-1}^2$$

Model ARIMA (3,2,1) yang telah diperoleh sebelumnya adalah :

$$Y_t = -0.754424Y_{t-1} - 0.999929e_{t-1}$$

Model ARIMA (3,2,1) + GARCH (0,1) adalah :

$$Y_t = 6.264 \times 10^5 x + 2.253 \times 10^{-1} \varepsilon_{t-1}^2 - 0.754424Y_{t-1} - 0.999929e_{t-1}$$

3.9 Peramalan

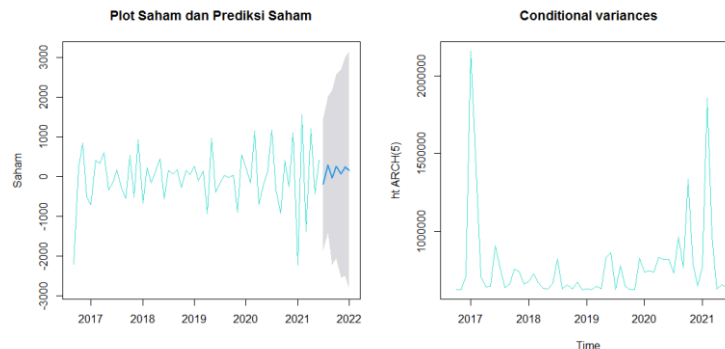
Setelah mendapatkan model terbaik yaitu ARIMA (3,2,1)-GARCH(0,1) maka dapat dilakukan peramalan data historis saham PT Kimia Farma untuk 7 bulan kedepan mulai Januari 2021-Juli 2021 adalah sebagai berikut :





Tabel 9. Peramalan Data Historis Saham PT Kimia Farma 7 Periode ke Depan

Periode	Forecast	Low	High
Juli 2021	-195.49930	-1850.535	1459.536
Agustus 2021	292.40099	-1418.703	2003.505
September 2021	-37.90582	-2238.674	2162.862
Oktober 2021	249.06222	-2058.803	2556.927
November 2021	70.34347	-2550.835	2691.522
Desember 2021	242.94988	-2514.442	3000.342



Gambar 5. Plot data prediksi saham dan conditional varians

Model ARCH terbaik yang didapatkan digunakan untuk peramalan data observasi pada bulan Juli tahun 2016 hingga bulan Juni 2021. Dari hasil ramalan yang diperoleh dapat dilihat bahwa untuk pergerakan saham PT. Kimia Farma Tbk. bergerak dinamis sehingga tidak membentuk pola tertentu.

IV. KESIMPULAN

Berdasarkan hasil analisis, maka penulis dapat menyimpulkan bahwa model GARCH(0,1) yang paling cocok digunakan dalam memprediksi data historis saham PT. Kimia Farma Tbk. Berdasarkan langkah pengujian yang telah dilakukan. Dari hasil perhitungan, model GARCH (0,1) memprediksi dengan sangat baik, karena nilai yang dihasilkan mengalami fluktuasi yang tidak terlalu signifikan untuk setiap periode. Diharapkan data ramalan yang didapat tersebut dapat memberikan sedikit informasi atau acuan mengenai waktu kapan investor atau para pemegang saham bisa membeli atau menjual sahamnya sesuai dengan kebutuhan. Selain itu, banyaknya data ramalan yang dapat digunakan untuk periode satu tahun kedepan tersebut juga dapat memberikan gambaran kepada investor atau broker saham mengenai keprospeekan saham PT. Kimia Farma Tbk. Besarnya tingkat ketidaktepatan pada peramalan bisa dipengaruhi oleh berbagai faktor ekonomi. Berdasarkan hasil peramalan juga dapat mengetahui kapan waktu yang baik untuk membeli ataupun menjual saham ini agar memperoleh keuntungan yang maksimal.





DAFTAR PUSTAKA

- [1] Ariefianto and M. Doddy, *Ekonometrika Esensi dan Aplikasi dengan Menggunakan EViews*. Jakarta: Erlangga, 2012.
- [2] A. P. Raneo and F. Muthia, "Penerapan Model GARCH Dalam Peramalan Volatilitas di Bursa Efek Indonesia," *J. Manaj. Dan Bisnis Sriwij.*, vol. 16, no. 3, pp. 194–202, 2019.
- [3] K. Nurfadilah, F. R. C, and I. Kasse, "Peramalan Tingkat Suku Bunga Pasar Uang Antar Bank (Puab) Dengan Vector Autoregressive Exogenous (Varx)," *J. MSA (Mat. dan Stat. serta Apl.)*, vol. 6, no. 1, p. 51, 2018.
- [4] S. Makridakis, S. C.Wheelright, and V. E.McGee, *Metode dan Aplikasi Peramalan*. Jakarta Barat: Binarupa Aksara, 1999.
- [5] Desvina and A. Pani, "Analisis Time Series Particulate Matter (PM10)," *Lemb. Penelit. dan Pengabd. Kpd. Masy. UIN SUSKA*, 2014.
- [6] Cryer, J. D., and K.-S. Chan, *Time Series Analysis with Application in R*, Second. Iowa City: Springer, 2008.
- [7] A. pani desvina dan Khairunisa, "Penerapan Metode Arch / Garch Dalam Meramalkan Transaksi Nilai Tukar (Kurs) Jual Mata Uang Indonesia (IDR) Terhadap Mata Uang Eropa (GBP)," *J. Sains Mat. dan Stat.*, vol. 4, no. 2, pp. 114–123, 2018.
- [8] F. Pakaja and A. Naba, "Peramalan Penjualan Mobil Menggunakan Jaringan Syaraf Tiruan dan Certainty Factor," *Neural Networks*, vol. 6, no. 1, pp. 23–28, 2015.

